Implementação e Análise de um Data Warehouse para Base de Dados de Publicações Científicas na Medicina

Erick S. S. Batista[1]

[1]Escola de Engenharia – Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte – MG – Brasil

Abstract. *This work aims to develop and analyze a Data Warehouse (DW) applied to a dataset of scientific publications in the medical field. The project is organized into stages that include dimensional modeling, the Extract, Transform, and Load (ETL) process, the selection of appropriate tools for storage and visualization, and the execution of exploratory analyses on the structured data. These analyses focus on identifying publication patterns, evolution over time, and the presence of hyperproductive authors. Through the construction of the DW, the study seeks to demonstrate how the consolidation and optimal organization of academic data can generate value and support knowledge discovery.*
Keywords*: Data Warehouse; Medical publications; Dimensional modeling; ETL (Extract, Transform and Load); Data analysis.*

Resumo. *Este trabalho tem como objetivo desenvolver e analisar um Data Warehouse (DW) aplicado a uma base de dados de publicações científicas na área médica. O projeto foi dividido em etapas que incluem a modelagem dimensional, o processo de extração, transformação e carga (ETL), a escolha de ferramentas adequadas para armazenamento e visualização, e a execução de análises exploratórias sobre os dados estruturados. As análises realizadas incluem a identificação de padrões de publicação, evolução temporal e a ocorrência de autores hiperprodutivos. A partir da construção do DW, espera-se demonstrar como a consolidação e a organização ideal dos dados podem gerar valor e conhecimento com dados acadêmicos.*
Palavras-chave*: Data Warehouse; Publicações médicas; Modelagem dimensional; ETL (Extração, Transformação e Carga); Análise de dados.*

1. Introdução

1.1. Contexto e Motivação

Este trabalho busca resolver o problema da dificuldade em estruturar, organizar e analisar grandes volumes de dados relacionados a publicações científicas na área da medicina. Embora existam muitas bases de dados públicas e privadas com milhares de registros sobre artigos científicos, esses dados geralmente se encontram de forma bruta ou distribuída em diferentes fontes, o que dificulta a extração de informações úteis e o reconhecimento de padrões relevantes. Além disso, a ausência de uma estrutura consolidada para análise pode limitar o potencial de geração de conhecimento a partir dessas informações.

A importância desse problema está ligada ao crescimento constante da produção científica. Com o aumento do volume de publicações, torna-se essencial o uso de soluções que facilitem o armazenamento organizado e a análise eficiente desse grande volume de dados. Um Data Warehouse (DW) é uma ferramenta apropriada para isso, pois permite integrar diferentes fontes, consolidar os dados em uma estrutura adequada e realizar análises complexas com rapidez e consistência.

Os principais benefícios esperados com a realização deste trabalho incluem: facilitar a análise exploratória de dados científicos na medicina, permitindo identificar padrões de publicação, autores com alta produtividade; oferecer um modelo replicável de DW que pode ser adaptado para outras áreas da ciência; e contribuir para a formação acadêmica do autor, através da aplicação prática de conceitos estudados em disciplinas relacionadas à Ciência de Dados, Bancos de Dados e Armazéns de Dados.

Dessa forma, o desenvolvimento deste projeto se justifica pela sua utilidade prática, relevância acadêmica e potencial de contribuição tanto para pesquisadores quanto para instituições interessadas em compreender melhor a produção científica na área médica.

1.2. Objetivos e Escopo

O objetivo geral deste trabalho é desenvolver e analisar um Data Warehouse (DW) para organizar e explorar dados de publicações científicas na área médica. A proposta visa oferecer uma estrutura robusta de armazenamento e análise que facilite a realização de consultas, a identificação de padrões e a extração de conhecimento relevante para pesquisadores, gestores e demais interessados na produção científica em medicina.

Como parte desse objetivo central, inicialmente busca-se identificar e selecionar uma base de dados representativa da produção científica na área médica. Essa base deve conter metadados relevantes como título, autores, instituições, palavras-chave, periódicos, data de publicação, entre outros, que possibilitem análises bibliométricas consistentes. O projeto utilizará bases de dados fornecidas por meio da colaboração com dois alunos de pós-graduação da universidade, juntamente com o docente orientador do projeto.

Em seguida, será realizada uma revisão dos principais conceitos e fundamentos teóricos relacionados a Data Warehouses, com ênfase nas suas aplicações em contextos de dados científicos. Essa etapa tem como objetivo compreender os elementos essenciais para a construção de um DW, incluindo sua arquitetura, modelagem dimensional, processos de ETL e mecanismos de consulta e visualização.

Com base nesse referencial teórico, será definida a modelagem mais adequada para o domínio dos dados de publicações científicas, optando entre o modelo estrela ou floco de neve. Nessa etapa serão identificadas as principais tabelas fato e dimensões, considerando métricas como número de publicações, número de citações, colaboração entre autores e distribuição temática, além de atributos descritivos como autor, instituição, periódico e área de conhecimento.

A escolha das ferramentas e tecnologias para implementação do DW será feita com base em critérios de viabilidade técnica e disponibilidade para fins acadêmicos. Será priorizado o uso de soluções gratuitas ou de código aberto, tais como PostgreSQL, ClickHouse, DuckDB, Apache Superset, Metabase, entre outras. Essa decisão permitirá a re-

produtibilidade do projeto e sua aplicação em ambientes com recursos limitados.

Outro objetivo importante é estruturar o processo de extração, transformação e carga (ETL) dos dados, assegurando que os dados oriundos das fontes selecionadas sejam tratados, normalizados e integrados de maneira adequada. Esse processo deve lidar com desafios como dados incompletos, inconsistências, ambiguidade de nomes e categorização temática, garantindo a qualidade dos dados inseridos no DW.

Após a construção do DW, serão realizadas análises exploratórias sobre o conteúdo da base, buscando identificar padrões de publicação ao longo do tempo, temas mais recorrentes na literatura médica, instituições e autores mais produtivos, bem como redes de colaboração científica. Tais análises contribuirão para demonstrar o potencial do DW como ferramenta de apoio à pesquisa e à tomada de decisão.

A avaliação dos resultados obtidos será conduzida por meio da verificação da eficácia do DW em termos de organização da informação, flexibilidade para consultas e capacidade de gerar insights relevantes. Essa etapa também inclui a análise da performance do sistema e a usabilidade das ferramentas de visualização escolhidas.

Por fim, todo o processo de desenvolvimento será documentado, com o intuito de justificar as decisões técnicas e adotadas ao longo do projeto. Essa documentação servirá como base para futuras replicações, melhorias ou adaptações do modelo em outras áreas do conhecimento científico.

2. Revisão Bibliográfica

A área de Data Warehouse (DW) tem se consolidado como uma das principais abordagens tecnológicas voltadas à integração e análise de grandes volumes de dados. O conceito de DW surgiu como uma resposta à crescente necessidade das organizações de armazenar dados históricos organizados para análise e suporte à decisão. O ciclo de vida de um DW foi estudado e desenvolvido incrementalmente por diversos autores ao longo dos anos (Figura 1). Hoje existem duas vertentes principais e mais utilizadas, que, apesar de terem princípios similares, ainda possuem diferenças importantes.

Segundo Inmon (Inmon 2005), considerado o pai do Data Warehouse, um DW é uma coleção de dados orientada por assunto, integrada, não volátil e variante no tempo. Sua abordagem é conhecida como ”top-down”, em que a construção do DW começa por um repositório central e, a partir dele, derivam-se os Data Marts. Inmon defende que o DW deve servir como base única para a tomada de decisões, sendo alimentado por processos de ETL robustos e bem definidos. Ele também enfatiza a importância da consistência dos dados ao longo do tempo para permitir análises confiáveis.

Complementarmente, Kimball e Ross (Kimball and Ross 2002) apresentam uma abordagem prática e voltada ao desempenho analítico. Diferente de Inmon, Kimball propõe uma metodologia ”bottom-up”, na qual se desenvolvem primeiro Data Marts departamentais que, integrados, formam um DW corporativo. Sua proposta é centrada na modelagem dimensional, que facilita a navegação pelos dados por meio de estruturas intuitivas, como os esquemas estrela (star schema) e floco de neve (snowflake schema) (Figura 2). Os autores descrevem detalhadamente o processo de identificação de fatos e dimensões, destacando a importância da granularidade, da conformidade de dimensões e da consistência nas métricas analíticas.

Figure 1. Ciclo de vida de um Data Warehouse

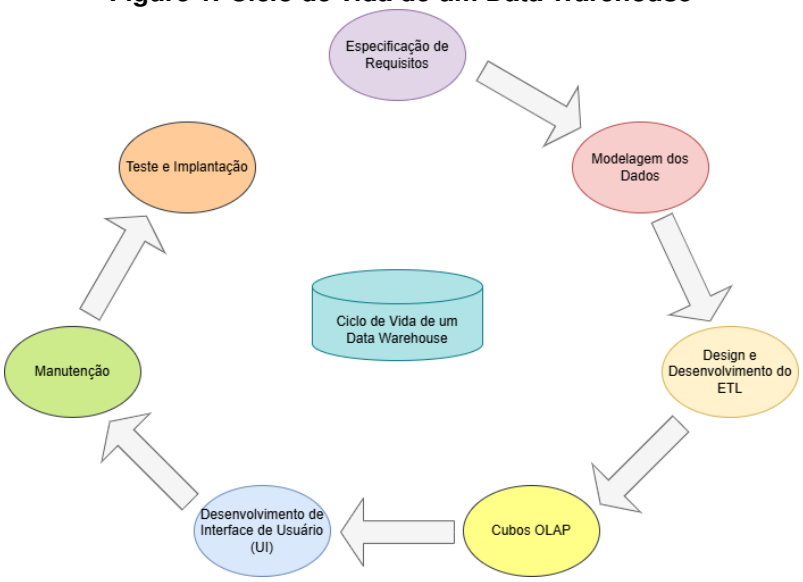

Figure 2. Comparação entre os esquemas Estrela e Floco de Neve

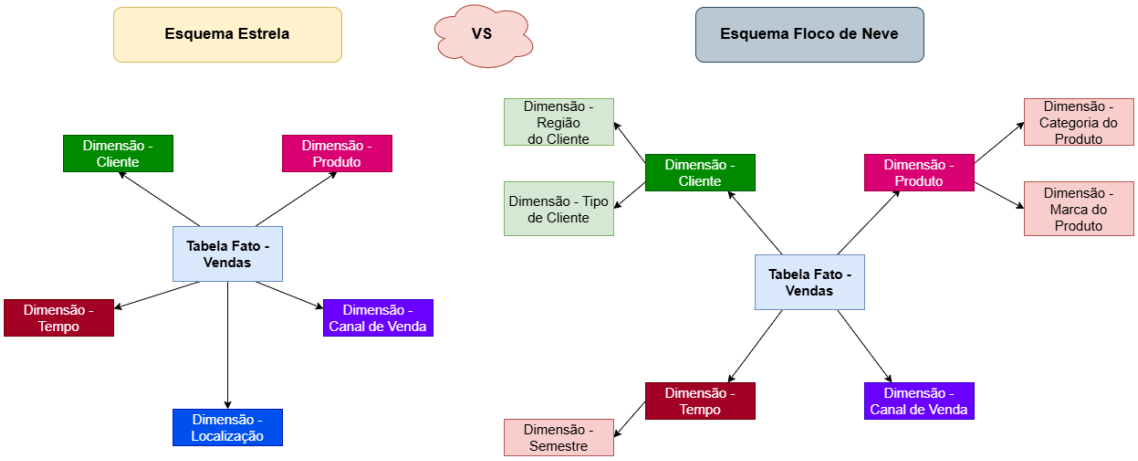

A comparação entre as abordagens de Inmon e Kimball revela diferenças fundamentais quanto à forma de estruturar e implementar um Data Warehouse. Inmon (Inmon 2005) propõe uma abordagem corporativa e centralizada, em que o Data Warehouse é desenvolvido como um repositório único, com foco na consistência e na integração de dados provenientes de toda a organização. O modelo relacional normalizado utilizado por Inmon visa garantir qualidade, controle e governança dos dados, embora possa resultar em maior complexidade nas consultas analíticas. Por outro lado, Kimball e Ross (Kimball and Ross 2002) priorizam uma abordagem mais pragmática e voltada ao negócio, em que Data Marts departamentais são desenvolvidos inicialmente com base em modelagem dimensional, formando posteriormente um Data Warehouse integrado. Essa abordagem bottom-up permite entregas rápidas de valor analítico, facilita o entendimento dos dados pelos usuários e simplifica o desenvolvimento de relatórios e dashboards. A Figura 3 resume as principais diferenças entre as abordagens dos autores e a usabilidade de cada uma.

Figure 3. Comparação entre as abordagens de Inmon e Kimball

-	Inmon	Kimball
Construção do DW	Consume muito tempo	Consume menos tempo
Manutenção	Fácil	Difícil, geralmente redundante e sujeita a revisões
Custo	Alto custo inicial; Custos subsequentes de desenvolvimento serão menores	Baixo custo inicial; Cada fase subsequente vai custar quase o mesmo
Tempo	Maior tempo para iniciar o projeto (organização inicial)	Menor tempo para iniciar o projeto (organização inicial)
Nível de habilidade requerido	Time especialista	Time generalista
Requisitos de integração de dados	Corporativa e centralizada	Departamental e voltada ao negócio
Metodologia	Top-down	Bottom-up
Estrutura	Dados não métricos, atende a várias necessidades de informação	Métricas de negócios, KPI's, indicadores de desempenho
Escalabilidade	Mudança de escopo e requisitos	Escopo limitado e necessidades voláteis

O desenvolvimento de um Data Warehouse segue um ciclo de vida estruturado, composto por diversas fases que visam garantir a construção de uma solução analítica robusta, eficiente e alinhada aos objetivos organizacionais. Segundo Kimball et al. (Kimball et al. 1998), o ciclo de vida de um DW envolve etapas como levantamento de requisitos, modelagem dimensional, projeto físico, desenvolvimento do processo de ETL, desenvolvimento de aplicações de front-end (consultas e relatórios), testes, implantação e manutenção. A abordagem enfatiza o desenvolvimento incremental por meio de entregas sucessivas de Data Marts integrados, o que permite gerar valor analítico já nas primeiras iterações. Kimball e Ross (Kimball and Ross 2002) reforçam a importância da modelagem dimensional como pilar do ciclo de vida, destacando que a criação de tabelas fato e dimensões deve estar fortemente vinculada às necessidades do negócio e ao entendimento das métricas utilizadas pela organização. A participação ativa dos usuários finais durante o ciclo é outro ponto fundamental na abordagem proposta, garantindo que o DW atenda de forma prática às demandas reais de análise e decisão. A Figura 4 mostra a arquitetura padrão de um DW, com todas etapas mais comuns do pipeline de dados.

Figure 4. Arquitetura de um Data Warehouse

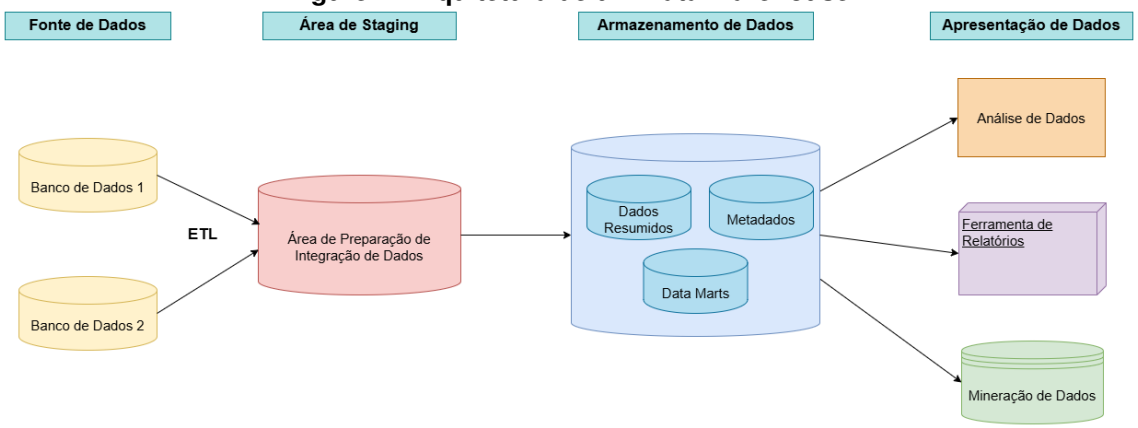

O modelo dimensional é considerado a espinha dorsal dos sistemas analíticos modernos. De acordo com Golfarelli e Rizzi (Golfarelli and Rizzi 2009), ele permite uma representação clara dos dados organizacionais, sendo composto por tabelas fato, que armazenam os eventos mensuráveis, e tabelas de dimensão, que descrevem o contexto desses fatos. O livro apresenta métodos modernos de projeto conceitual e lógico para ambientes analíticos, além de explorar o papel das ferramentas OLAP e dos algoritmos de agregação na construção de sistemas eficientes.

Em paralelo, o conceito de Data Marts é abordado tanto por Inmon quanto por Kimball como uma forma de especialização do DW. Enquanto Inmon os vê como subcon-

juntos derivados de um DW corporativo, Kimball os considera como unidades autônomas que se integram futuramente. A utilização de Data Marts permite que equipes especializadas tenham acesso rápido a dados relevantes ao seu domínio, o que, segundo Inmon (Inmon 2005), favorece uma abordagem incremental à construção do DW.

Um dos principais recursos utilizados em ambientes de Data Warehouse (DW) é o OLAP (Online Analytical Processing), responsável por permitir a realização de consultas multidimensionais rápidas e flexíveis sobre grandes volumes de dados. Segundo Chaudhuri e Dayal (Chaudhuri and Dayal 1997), OLAP é uma tecnologia essencial para dar suporte a análises complexas e tomadas de decisão baseadas em dados históricos. As operações típicas de OLAP incluem drill-down, que permite aprofundar a análise em níveis mais detalhados (por exemplo, de ano para trimestre, mês ou dia); roll-up, que faz o movimento oposto, agregando os dados em níveis mais altos de abstração; slice, que consiste na seleção de uma única dimensão para análise (por exemplo, visualizar apenas os dados de um ano específico); e dice, que permite selecionar múltiplas dimensões e valores ao mesmo tempo, criando subconjuntos específicos dos dados para análise cruzada.

Além das operações, Chaudhuri e Dayal (Chaudhuri and Dayal 1997) explicam as diferenças entre os três principais tipos de arquitetura OLAP: MOLAP, ROLAP e HOLAP. O MOLAP (Multidimensional OLAP) utiliza estruturas multidimensionais para armazenar os dados em forma de cubos, o que permite respostas rápidas para consultas analíticas, graças ao pré-processamento e armazenamento de agregações. No entanto, essa abordagem pode ter limitações em relação ao volume de dados que consegue armazenar e processar, além de exigir mais espaço de armazenamento para manter os cubos gerados.

O ROLAP (Relational OLAP), por outro lado, utiliza bancos de dados relacionais tradicionais para armazenar os dados e executa as consultas diretamente sobre eles, o que permite lidar com volumes muito maiores de dados e aproveitar as capacidades de otimização dos SGBDs relacionais. Contudo, essa abordagem tende a ter desempenho inferior em consultas mais complexas, pois não utiliza pré-agregações como o MOLAP, dependendo de cálculos em tempo de execução.

Por fim, o HOLAP (Hybrid OLAP) busca combinar as vantagens dos dois modelos anteriores. Nesse tipo de arquitetura, os dados detalhados permanecem no banco relacional (ROLAP), enquanto as agregações mais utilizadas são pré-calculadas e armazenadas em estruturas multidimensionais (MOLAP), otimizando o desempenho para as consultas mais comuns, sem perder a escalabilidade e flexibilidade de acesso aos dados detalhados. Essa abordagem híbrida é especialmente útil em cenários que exigem tanto performance quanto capacidade de armazenamento e granularidade analítica.

Além disso, para que o DW contenha dados atualizados, integrados e prontos para análise, é necessário um processo robusto de ETL (Extract, Transform, Load). Vassiliadis (Vassiliadis 2000) apresenta uma análise detalhada sobre as tecnologias de ETL, abordando os desafios na integração de dados de múltiplas fontes, a transformação para garantir consistência e qualidade, e o carregamento eficiente no repositório de dados. O autor argumenta que o ETL é muitas vezes subestimado, apesar de ser responsável por grande parte do esforço técnico em projetos de DW.

Kanashiro (Kanashiro 2007) desenvolveu um projeto de Data Warehouse voltado

para a área científica, mais especificamente no domínio da ciência da computação, com o objetivo de estruturar e organizar grandes volumes de publicações coletadas automaticamente da Web. O DW proposto foi integrado à Ferramenta Inteligente de Apoio à Pesquisa (FIP), concebida para facilitar a recuperação, organização e análise visual de documentos científicos. Um dos principais diferenciais do trabalho é a proposta de automatizar a indexação da dimensão ”tópicos de pesquisa” nos data marts por meio de algoritmos de aprendizado de máquina, permitindo a categorização sem intervenção manual. Essa abordagem facilitou a análise da evolução temática ao longo do tempo, permitindo detectar tendências emergentes na produção científica. Esse trabalho é relevante para o presente estudo, pois demonstra a viabilidade e os benefícios da aplicação de técnicas de Data Warehousing em contextos de produção científica, servindo como uma importante referência para a estruturação de repositórios analíticos similares na área da medicina, além de fornecer ideias de análises exploratórias interessantes a serem feitas sobre dados científicos.

O presente trabalho propõe unir as práticas e fundamentos discutidos na literatura para desenvolver um DW voltado especificamente para dados de publicações científicas na área médica. A originalidade do projeto está na aplicação dessas técnicas ao domínio da medicina, utilizando dados reais e ferramentas modernas de código aberto para permitir análises como frequência de publicação, tópicos recorrentes e autores com alta produtividade. Espera-se que essa abordagem contribua para o avanço das pesquisas científicas e forneça uma base sólida para futuras aplicações analíticas na área da saúde.

3. Impactos

A construção de um Data Warehouse (DW) voltado para a análise de publicações científicas na área médica possui potencial para gerar impactos relevantes em múltiplas dimensões — social, científica, tecnológica e estratégica. Mais do que um exercício acadêmico, este trabalho se alinha a necessidades reais de instituições de ensino, centros de pesquisa e órgãos governamentais, demonstrando a aplicabilidade prática de soluções de Engenharia de Sistemas voltadas para ciência de dados.

Como impactos sociais, podemos destacar que a organização estruturada dos dados científicos facilita muito o acesso às informações por parte de pesquisadores, estudantes e profissionais da saúde. Em vez de cada um precisar buscar manualmente em diferentes bases de dados, o DW oferece uma visão centralizada e confiável, o que pode acelerar pesquisas e estudos em áreas críticas, como doenças emergentes ou novas tecnologias médicas. Além disso, ao democratizar o acesso às informações científicas, o projeto também contribui para a transparência e a disseminação do conhecimento, algo essencial para o fortalecimento da educação e da pesquisa no país.

Já em termos científicos, o DW permite a realização de análises bibliométricas muito mais robustas e sistemáticas. Com os dados bem estruturados, é possível identificar tendências na produção científica, áreas da medicina que estão em crescimento, pesquisadores que mais publicam (os chamados hiperprodutivos) e até redes de colaboração entre instituições de diferentes países. Essas análises ajudam não só pesquisadores individuais, mas também órgãos de fomento e gestores de ciência e tecnologia, que podem tomar decisões melhores sobre onde investir recursos. Além disso, o fato de usar ferramentas abertas e metodologias replicáveis coloca o trabalho em sintonia

com os princípios da ciência aberta, o que aumenta a transparência e a reprodutibilidade.

Do ponto de vista tecnológico, o projeto mostra como é possível implementar soluções modernas de engenharia de dados usando ferramentas acessíveis e open-source. Tecnologias como bancos de dados colunares, pipelines de ETL bem estruturados e ferramentas de visualização interativa tornam possível montar um ambiente de análise eficiente mesmo em contextos com poucos recursos, como muitas vezes acontece em projetos acadêmicos. Isso prova que não é preciso ter uma infraestrutura cara para aplicar conceitos avançados de Data Warehousing e análise de dados, o que amplia as possibilidades de uso em diferentes áreas.

Por fim, ao pensar de forma mais ampla, esse trabalho também tem um impacto estratégico quando visto sob a ótica da Engenharia de Sistemas. Isso porque não se trata apenas de juntar ferramentas tecnológicas, mas de integrar pessoas, processos e informações em um sistema único que gera valor. A construção do DW exige um olhar sistêmico para cada etapa: desde a coleta e tratamento dos dados até a entrega final em forma de dashboards e análises. Esse tipo de abordagem mostra como a Engenharia de Sistemas pode contribuir para resolver problemas reais, unindo tecnologia, ciência e sociedade em uma solução integrada.

Em resumo, o DW proposto não se limita a armazenar publicações científicas, mas pode servir como um instrumento estratégico para apoiar decisões em pesquisa, saúde pública e políticas científicas. Ele gera impacto social ao democratizar o acesso à informação, impacto científico ao permitir análises avançadas sobre a produção acadêmica, impacto tecnológico ao mostrar a viabilidade de ferramentas acessíveis e impacto sistêmico ao colocar em prática conceitos fundamentais da Engenharia de Sistemas.

4. Metodologia

Este trabalho será conduzido por meio da implementação completa de um Data Warehouse (DW) voltado à análise de publicações científicas na área médica. A metodologia proposta segue o ciclo tradicional de desenvolvimento de um DW, adaptado ao escopo acadêmico e com ferramentas open-source adequadas para um ambiente de TCC.

A primeira etapa envolve a modelagem dimensional da base de dados, utilizando o pgModeler, que possibilita a construção de modelos conceituais e físicos de forma visual e integrada com PostgreSQL, mas também exportáveis para uso com DuckDB. A modelagem terá como base o esquema estrela, considerando tabelas de fatos e dimensões relevantes às análises.

Na segunda etapa, será realizada a extração, transformação e carga dos dados (ETL) com o uso do DuckDB, um banco analítico colunar leve e eficiente, que permite a execução de consultas complexas localmente, sem a necessidade de configuração de servidores, tornando-o ideal para projetos acadêmicos com foco em prototipagem e análise.

Os dados tratados serão armazenados no PostgreSQL, um sistema de banco de dados relacional de código aberto amplamente utilizado pela sua confiabilidade, desempenho e flexibilidade. Ele permite a execução de consultas complexas e oferece bom suporte para análise de dados, integração com ferramentas de BI e manipulação de grandes

volumes de informação. Por ser gratuito e amplamente documentado, o PostgreSQL é uma excelente opção para projetos acadêmicos e de prototipagem.

Por fim, será feita a visualização e análise exploratória dos dados no Metabase, ferramenta que permite a criação de dashboards interativos e análises simples, ideal para comunicar de forma clara os padrões extraídos dos dados.

4.1. Cronograma

As principais etapas a serem desenvolvidas no projeto, bem como o cronograma de realização destas etapas, podem ser vistos na Tabela 1.

Table 1. Cronograma de realização do trabalho

Etapa	Atividade	Data Limite
1.1	Levantamento inicial sobre conceitos de DW e revisão de referências principais (Inmon, Kimball, etc.)	10/abr/25
1.2	Estudo de ferramentas candidatas (pgModeler, DBT, DuckDB, Metabase) e justificativa da escolha	25/abr/25
2.1	Coleta preliminar de amostras da base de dados fornecida (Excel/CSV)	10/mai/25
2.2	Análise exploratória e definição do dicionário de dados (atributos, chaves naturais, inconsistências)	25/mai/25
3.1	Definição do grão do DW e escolha das tabelas fato principais	10/jun/25
3.2	Definição das dimensões e tabelas de ponte (autores, instituições, keywords)	25/jun/25
4.1	Construção do staging e limpeza de dados brutos (remoção de duplicatas, normalização básica)	10/jul/25
4.2	Implementação das transformações e regras de qualidade no processo de ETL	25/jul/25
5.1	Criação do esquema físico no DuckDB e carga inicial de dados tratados	10/ago/25
5.2	Testes de integridade referencial e performance das consultas no DW	25/ago/25
6.1	Configuração inicial do Metabase e criação de dashboards básicos (publicações por ano, top autores)	10/set/25
6.2	Expansão dos dashboards com análises temáticas, colaboração entre instituições e autores	25/set/25
7.1	Redação e organização da seção de resultados obtidos a partir do DW	10/out/25
7.2	Revisão geral do trabalho, ajustes finais e preparação para defesa	25/out/25

O cronograma do trabalho foi pensado para dividir as atividades em etapas menores, com prazos bem definidos, de forma que o projeto avance de maneira organizada e contínua. Primeiro, temos um levantamento inicial sobre os conceitos de Data Warehouse e a revisão das principais referências da área, além do estudo e escolha das ferramentas que serão usadas. Essa parte é importante para garantir que o projeto tenha uma base sólida e que as decisões técnicas sejam bem justificadas.

Na sequência, entra a parte prática da coleta dos dados. Primeiro fazemos uma coleta preliminar de amostras no formato Excel/CSV e depois uma análise exploratória para entender os atributos disponíveis, as chaves e possíveis inconsistências. A ideia aqui é montar um dicionário de dados que vai guiar toda a modelagem.

Depois disso, partimos para a modelagem dimensional, definindo as tabelas fato e dimensões, além de escolher o nível de detalhe adequado para as análises. Em paralelo, começa a preparação do processo de ETL: construção do ambiente de staging, limpeza dos dados brutos (como remoção de duplicatas e normalizações básicas) e implementação das regras de transformação e de qualidade. Essa etapa é crítica porque garante que os dados que vão alimentar o DW sejam consistentes e confiáveis.

Com a modelagem pronta e os dados tratados, partimos para a implementação do DW propriamente dito e realizamos os testes de integridade e performance, para ter certeza de que o sistema está funcionando bem e respondendo às consultas dentro do esperado.

Na fase seguinte, começa a parte de visualização dos resultados. Primeiro, configuramos o Metabase e criamos dashboards básicos com informações mais diretas, como número de publicações por ano ou os autores mais produtivos. Depois, esses dashboards

são expandidos para incluir análises mais complexas, como colaboração entre instituições, redes de autores e distribuição temática das publicações.

Por fim, o trabalho entra na etapa de análise dos resultados, organização das conclusões e extração de valor do dados.

5. Desenvolvimento e Implementação

O desenvolvimento do Data Warehouse (DW) proposto neste trabalho seguiu um fluxo sistemático que integra as etapas clássicas de um projeto de engenharia de dados: obtenção de dados brutos, modelagem dimensional, tratamento e padronização, armazenamento em ambiente relacional e, por fim, visualização e análise exploratória. A Figura 5 e as consultas descritas a seguir ilustram como cada uma dessas fases foi conduzida e implementada.

5.1. Coleta e Estruturação Inicial dos Dados

O ponto de partida deste projeto foi a coleta e utilização de dados provenientes da base Scopus, uma das principais plataformas mundiais de indexação de publicações científicas. O **Scopus** é amplamente utilizado por instituições de ensino e pesquisa, pois reúne metadados de artigos, periódicos, autores, afiliações e áreas de conhecimento, permitindo análises bibliométricas de alta qualidade.

Os dados possuem informações de publicações científicas na área da medicina de 2010 a 2024, foram fornecidos em formato **CSV** e organizados em quatro bases principais. Cada uma das quatro bases contém informações complementares:

- **author_index**: contém os identificadores e nomes dos autores (total de aproximadamente 11,32 milhões de registros);
- **venue_index**: contém os identificadores e nomes dos locais de publicação, como periódicos e conferências (cerca de 15,18 mil registros);
- **paper_index**: contém os títulos e identificadores dos artigos científicos (aproximadamente 16,61 milhões de registros);
- **complete_graph**: representa a relação entre autores, artigos, locais de publicação e o ano da publicação, funcionando como uma tabela relacional completa, com cerca de 55,71 milhões de registros. Nessa base, uma publicação aparece repetida para cada autor e para cada local em que foi publicada.

Essas bases constituem a camada de dados brutos do projeto. A partir delas, iniciou-se o processo de modelagem e construção do Data Warehouse.

5.2. Modelagem Dimensional

Antes da manipulação e transformação dos dados, foi elaborada a modelagem dimensional utilizando a ferramenta pgModeler. Essa etapa teve como objetivo definir a estrutura lógica e física do DW, estabelecendo as tabelas fato e dimensões, suas chaves primárias e estrangeiras, bem como os relacionamentos entre elas.

O modelo desenvolvido segue a abordagem de Kimball e Ross (Kimball and Ross 2002), adotando o **esquema estrela (star schema)** como base, devido à sua simplicidade e eficiência em consultas analíticas. O modelo foi composto por três dimensões e uma tabela fato:

- **dim_authors**: contendo as informações dos autores (*author_id*, *author*);
- **dim_venues**: armazenando os locais de publicação (*venue_id*, *venue*);
- **dim_papers**: contendo os artigos científicos (*paper_id*, *paper*);
- **fact_publications**: relacionando as publicações com seus autores, locais e anos de publicação (*id*, *paper_id*, *author_id*, *venue_id*, *year*).

Para garantir unicidade dos registros na tabela fato, foi criada uma coluna *id* como chave primária, já que as combinações entre autor, artigo e local se repetem no conjunto de dados.

A Figura 5 apresenta o modelo estrela criado no pgModeler, representando a estrutura lógica do DW utilizada como base para o processo de integração e carga de dados. Fica aparente que a estrutura do DW para estes dados não é complexa, sendo composta por uma tabela fato e três tabelas dimensão, mas é uma estrutura extensível e escalável, que vai permitir aumentar o número de dimensões, e até de fatos, de forma simplificada, após a estrutura básica ser desenvolvida.

Figure 5. Modelo estrela do Data Warehouse desenvolvido no pgModeler

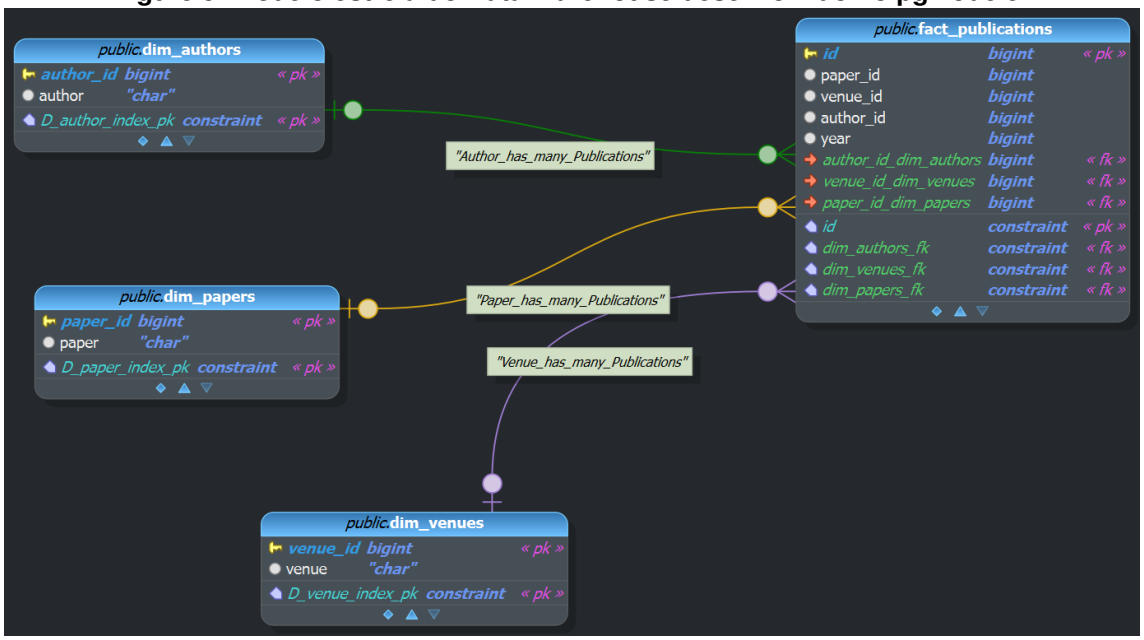

5.3. Tratamento e Padronização dos Dados (ETL Local com DuckDB)

Após a modelagem, iniciou-se a etapa de **tratamento, limpeza e padronização dos dados**, que corresponde à fase de **staging** no ciclo de vida de um DW. Essa etapa foi conduzida integralmente no **DuckDB**, um banco de dados analítico colunar leve e de execução local.

As consultas SQL foram executadas diretamente no computador local, sem necessidade de servidor, o que permitiu manipular grandes volumes de dados de forma eficiente. O processo incluiu:

- Contagem de registros e amostragem inicial das bases;
- Criação de tabelas no DuckDB a partir dos arquivos CSV;

- Remoção de registros com valores nulos em colunas de identificação;
- Eliminação de duplicatas;
- Correção da coluna *time*, que representava apenas os dois últimos dígitos do ano, transformando-a em *year*;
- Validação de integridade e consistência dos dados tratados (verificação da unicidade das chaves principais, algumas medidas analíticas para teste de consistência etc.)

O código a seguir exemplifica parte do processo de correção e transformação da coluna de tempo:

```
CREATE TABLE complete_graph_timefix AS
SELECT *,
CASE
  WHEN "time" BETWEEN 0 AND 25 THEN "time" + 2000
  WHEN "time" BETWEEN 25 AND 99 THEN "time" + 1900
  ELSE "time"
END AS year_full
FROM complete_graph_clean;
```

Após a limpeza e padronização, foram criadas as tabelas finais que compõem o DW:

```
CREATE TABLE fact_publications AS
SELECT paper_id, author_id, venue_id, year_full
FROM complete_graph_timefix;

CREATE TABLE dim_authors AS
SELECT DISTINCT author_id, author_name FROM author_index_clean;

CREATE TABLE dim_venues AS
SELECT DISTINCT venue_id, venue_name FROM venue_index_clean;

CREATE TABLE dim_papers AS
SELECT DISTINCT paper_id, title FROM paper_index_clean;
```

As consultas realizadas para auditoria incluíram análises de contagem, distribuição temporal e verificação dos autores e venues mais produtivos. A Figura 6 ilustra as tabelas finais geradas e visualizadas no DuckDB após o processo de ETL local.

Figure 6. Tabelas finais criadas no DuckDB após o processo de ETL

database varchar	schema varchar	name varchar	column_names varchar[]	column_types varchar[]	temporary boolean
duckdb_bases_versao_leve	main	dim_authors	[author_id, author]	[BIGINT, VARCHAR]	false
duckdb_bases_versao_leve	main	dim_papers	[paper_id, paper]	[BIGINT, VARCHAR]	false
duckdb_bases_versao_leve	main	dim_venues	[venue_id, venue]	[BIGINT, VARCHAR]	false
duckdb_bases_versao_leve	main	fact_publications	[id, paper_id, author_id, venue_id, year]	[BIGINT, BIGINT, BIGINT, BIGINT, BIGINT]	false

5.4. Armazenamento e Acesso no PostgreSQL (Produção/Consumo)

Com os dados já tratados e validados, as bases finais foram exportadas em formato **CSV** e ingeridas, posteriormente, no **PostgreSQL**, um sistema gerenciador de banco de dados relacional robusto e amplamente utilizado em ambientes de produção.

Essa etapa corresponde à **fase de produção e consumo** do DW, onde os dados passam a ser armazenados de forma persistente, segura e consistente. O PostgreSQL foi escolhido por garantir integridade referencial, controle de transações e facilidade de integração com ferramentas analíticas, servindo como base para as consultas e visualizações realizadas posteriormente.

5.5. Visualização e Análise Exploratória com Metabase

A etapa final do projeto consistiu na **exploração e análise visual dos dados**, realizada com a ferramenta **Metabase**. O Metabase foi executado em um ambiente containerizado via **Docker**, o que garantiu isolamento, portabilidade e facilidade de configuração, sem necessidade de instalação direta na máquina local.

Conectado ao banco PostgreSQL, o Metabase possibilitou a criação de dashboards interativos e dinâmicos, que sintetizam as principais métricas e insights obtidos a partir do DW. Entre as análises desenvolvidas, destacam-se:

- Evolução temporal das publicações científicas na área médica;
- Autores mais produtivos;
- Locais de publicação mais relevantes e sua distribuição de artigos;
- Média de autores e de locais por publicação;
- Percentual de publicações colaborativas (com mais de um autor);
- Distribuição do número de autores por artigo e por periódico.

Essas análises demonstraram como a consolidação de dados em um modelo dimensional bem estruturado pode apoiar a geração de conhecimento científico e a tomada de decisão baseada em dados, confirmando a aplicabilidade prática do Data Warehouse desenvolvido.

A Figura 7 e a Figura 8 apresentam exemplos de visualizações obtidas com o Metabase, representando o produto final do projeto.

6. Resultados e Discussão

A partir da estruturação e implementação do Data Warehouse desenvolvido, foi possível realizar uma série de análises exploratórias e construir visualizações que sintetizam informações relevantes sobre as publicações científicas na área médica. Os resultados apresentados refletem a importância da organização e integração dos dados, evidenciando como o uso de técnicas de engenharia de sistemas e ferramentas analíticas pode transformar dados dispersos em conhecimento acessível.

6.1. Principais Análises Realizadas

As análises foram conduzidas no **Metabase**, com base no modelo dimensional hospedado no **PostgreSQL**. Entre as visões geradas, destacam-se aquelas relacionadas à

Figure 7. Dashboard gerado no Metabase - Parte 1

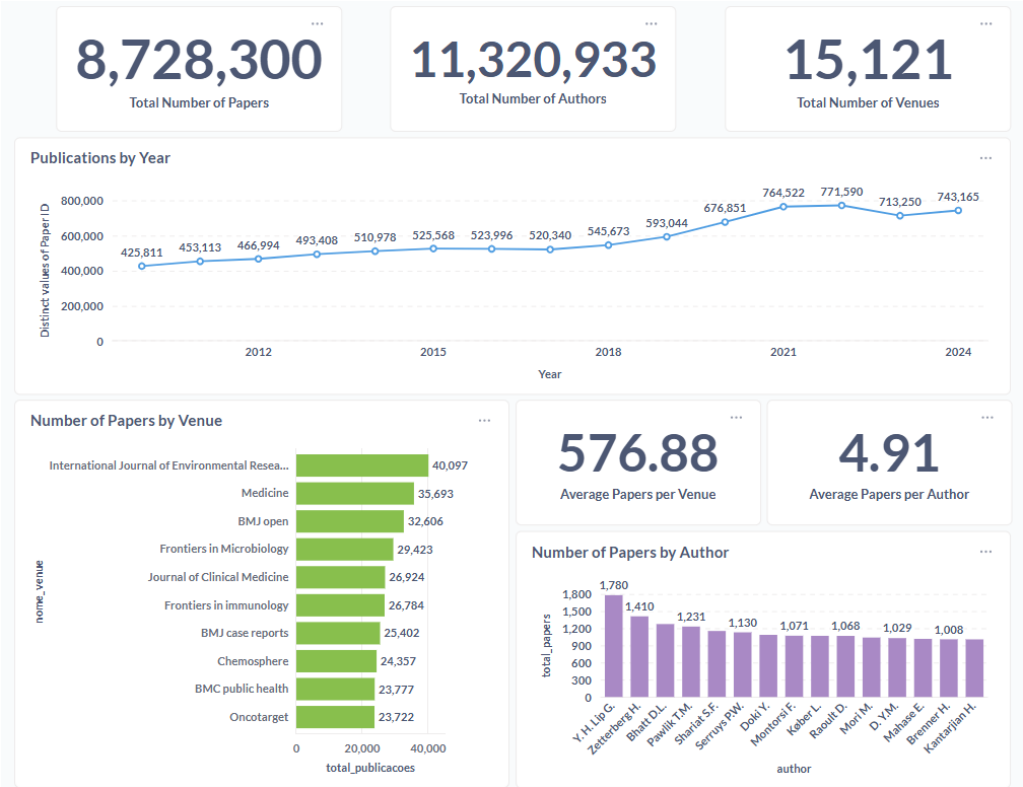

quantidade total de publicações, número de autores e locais de publicação, bem como a evolução temporal das publicações ao longo dos anos.

A partir dessas visualizações, foi possível observar padrões de crescimento da produção científica, identificar autores mais produtivos e locais de publicação com maior concentração de artigos. Além disso, métricas complementares, como o número médio de publicações por autor e por local, a distribuição de autores por artigo e o percentual de publicações com mais de um autor, permitiram compreender aspectos colaborativos da pesquisa científica na área médica.

Apesar da relevância desses achados, algumas limitações foram observadas. As bases de dados originais não continham informações sobre países de origem, afiliações institucionais, citações ou áreas temáticas dos artigos, o que restringiu a realização de análises mais profundas de caráter geográfico ou temático. Essas dimensões, embora relevantes para estudos bibliométricos mais amplos, não estavam disponíveis no conjunto de dados utilizado. Tais limitações, no entanto, abrem espaço para trabalhos futuros, que podem incorporar técnicas de *Natural Language Processing* (NLP) para a classificação automática dos temas das publicações e análise de tendências científicas.

6.2. Análise dos Dashboards e Resultados Obtidos

A análise dos dados tratados e modelados no Data Warehouse resultou na criação de um conjunto de dashboards interativos no Metabase, que sintetizam informações relevantes sobre o volume de publicações científicas, produtividade de autores e padrões de colaboração.

Figure 8. Dashboard gerado no Metabase - Parte 2

Os resultados mostram que o conjunto de dados utilizado contém aproximadamente **8,7 milhões de publicações**, **11,3 milhões de autores** e **15 mil locais de publicação**. Esses números evidenciam a dimensão e a abrangência da base de dados, que consolida uma grande parte da produção científica da área médica proveniente do *Scopus*. É possível observar, pela série temporal de publicações (Figura 7), um crescimento consistente ao longo dos anos, especialmente a partir de 2018, o que reflete a expansão das pesquisas médicas e biomédicas nas últimas décadas.

O gráfico "*Number of Papers by Venue*" demonstra que alguns periódicos concentram uma parcela significativa da produção científica. Revistas como *International Journal of Environmental Research and Public Health* e *Medicine* aparecem entre as mais produtivas, indicando sua relevância e popularidade entre os pesquisadores da área médica. Esse tipo de informação pode auxiliar gestores e instituições na escolha de canais estratégicos para divulgação científica.

No painel de autores, nota-se uma forte concentração de produtividade em poucos indivíduos: alguns autores ultrapassam 1.000 publicações, com destaque para nomes que possuem histórico de colaboração extensa ou atuação em grandes grupos de pesquisa. Esse padrão é comum em bases de larga escala, onde há autores hiperprodutivos que lideram projetos colaborativos ou revisões sistemáticas.

A Figura 8 aprofunda a análise da colaboração científica. A distribuição do número de autores por publicação mostra que **mais de 93% dos artigos possuem mais de um autor**, com média de aproximadamente **6,4 autores por artigo**. Esse resultado confirma a tendência de aumento na colaboração interdisciplinar e internacional em pesquisas médicas. Por outro lado, a média de **1 local de publicação por artigo** reflete a estrutura natural do processo editorial, em que cada artigo é publicado em um único periódico.

Além disso, os indicadores de média — cerca de **576 publicações por local de publicação** e **4,9 publicações por autor** — indicam uma distribuição assimétrica, em que poucos autores e periódicos concentram uma grande parte das publicações. Essa observação reforça a importância de análises baseadas em métricas de concentração e impacto.

De modo geral, os dashboards evidenciam que o Data Warehouse desenvolvido cumpre seu papel de organizar e facilitar a exploração de grandes volumes de dados

científicos, permitindo uma visualização clara e integrada dos padrões de publicação, produtividade e colaboração na medicina. A facilidade de navegação e a interatividade oferecida pelo Metabase tornam a análise acessível até mesmo a usuários sem conhecimento técnico avançado, demonstrando o potencial da solução para apoiar decisões e estudos acadêmicos.

6.3. Desempenho e Usabilidade das Ferramentas

Durante a execução das consultas e geração das visualizações, observou-se que o desempenho das ferramentas variou conforme a etapa do processo. O **DuckDB** apresentou excelente eficiência nas tarefas de limpeza e transformação dos dados, processando grandes volumes de forma local e leve. Já o **PostgreSQL**, utilizado na fase de produção, apresentou desempenho aceitável, mas com lentidão perceptível em algumas consultas mais complexas.

O **Metabase**, por sua vez, mostrou-se uma solução prática e intuitiva para visualização, mas apresentou certa lentidão ao carregar dashboards com grandes volumes de dados, especialmente em análises agregadas. Em uma das visões do dashboard foi necessário deixar uma visão agregada pronta, já no ambiente relacional do PostgreSQL, para poupar processamento no Metabase, e possibilitar o carregamento de todas as visões do dashboard. Mesmo assim, a ferramenta se destacou pela facilidade de uso, clareza das visualizações e valor analítico das informações apresentadas.

No geral, a combinação das ferramentas adotadas proporcionou um ambiente analítico completo e coerente com o propósito do trabalho: dados tratados e integrados, consultas SQL diretas e visualizações acessíveis. Essa estrutura tornou possível demonstrar, na prática, os benefícios de um Data Warehouse bem projetado — organização, rastreabilidade e suporte à análise de dados complexos.

6.4. Limitações e Considerações sobre o Modelo Desenvolvido

As principais limitações encontradas neste trabalho estão associadas à simplicidade e à incompletude das bases de dados disponíveis. Os arquivos continham poucos atributos por entidade (autores, artigos venues e anos), o que restringiu o potencial de análises multidimensionais. A ausência de dados contextuais, como instituições, países ou palavras-chave, limitou a exploração de relações mais profundas entre as publicações.

Outro ponto observado foi o desempenho das consultas no ambiente relacional, especialmente durante a exploração visual. Embora o PostgreSQL tenha garantido a integridade e consistência dos dados, a execução de consultas sobre grandes volumes exigiu mais recursos computacionais, tornando o uso do **DuckDB** uma alternativa interessante para análises locais e mais rápidas.

Apesar dessas limitações, os resultados obtidos demonstram que a modelagem dimensional e o processo de ETL implementados foram eficazes para garantir a qualidade e consistência dos dados. O modelo em estrela se mostrou adequado e flexível, permitindo que as análises fossem conduzidas de forma intuitiva e eficiente.

6.5. Vantagens do Data Warehouse em relação a Bancos de Dados Tradicionais

Durante o desenvolvimento deste trabalho, ficou evidente a diferença entre o papel

de um banco de dados transacional e o de um *Data Warehouse* (DW). Enquanto os bancos de dados convencionais são voltados para o registro e gerenciamento de transações diárias, como inserções, atualizações e exclusões, o DW é projetado para consolidar e analisar grandes volumes de dados históricos, com o objetivo de apoiar a tomada de decisão estratégica.

Em um banco de dados tradicional, o foco está na **velocidade de resposta e consistência das transações**. Esse tipo de sistema, conhecido como OLTP (*Online Transaction Processing*), é ideal para aplicações operacionais, mas não é otimizado para consultas analíticas complexas. Já o DW utiliza o paradigma OLAP (*Online Analytical Processing*), que permite análises multidimensionais, agregações e comparações de longo prazo.

Outra diferença marcante está na **origem e estrutura dos dados**. Um banco transacional costuma receber informações de uma única aplicação, enquanto o DW integra dados de múltiplas fontes — no caso deste projeto, as bases *author_index*, *venue_index*, *paper_index* e *complete_graph*, provenientes do Scopus. Essa integração garante uma visão unificada e consistente do domínio analisado.

Além disso, o DW trabalha com dados **históricos e consolidados**, permitindo identificar tendências e padrões de comportamento ao longo do tempo. Essa característica foi essencial para as análises realizadas neste trabalho, que exploraram a evolução das publicações médicas, a produtividade de autores e os locais mais frequentes de publicação.

Do ponto de vista dos usuários, os bancos de dados transacionais atendem a muitos usuários simultaneamente, com necessidades operacionais variadas. Já o DW é utilizado por um grupo mais restrito de analistas, pesquisadores ou gestores, cujo objetivo é extrair conhecimento e apoiar decisões baseadas em evidências. Essa diferença reflete diretamente no design do sistema e na otimização das consultas.

Em resumo, o **Data Warehouse complementa o banco de dados tradicional**, oferecendo uma camada analítica estruturada, histórica e consolidada. No contexto deste trabalho, isso significou a transição de um conjunto disperso de arquivos CSV para uma estrutura organizada, integrada e capaz de gerar visualizações e insights estratégicos. Essa diferença ilustra, na prática, o valor que a Engenharia de Sistemas agrega ao transformar dados brutos em informação útil e acionável.

6.6. Relação com a Engenharia de Sistemas e Ciência Aberta

Sob a ótica da **Engenharia de Sistemas**, este projeto demonstra a importância de se pensar o sistema de dados como um todo, desde a origem até a entrega da informação analisada. O desenvolvimento do Data Warehouse envolveu etapas integradas de modelagem, integração, transformação, validação e visualização, refletindo o pensamento sistêmico aplicado à gestão de dados científicos.

Além disso, a escolha por ferramentas como o **pgModeler**, o **DuckDB**, o **PostgreSQL**, e o **Metabase** reforça o compromisso com os princípios da ciência aberta e da replicabilidade. Todas essas ferramentas são de código aberto, relativamente leves e acessíveis, permitindo que qualquer pesquisador ou estudante possa reproduzir o ambiente e as análises desenvolvidas sem necessidade de infraestrutura pesada ou custos adicionais. Essa característica torna o modelo proposto especialmente relevante para con-

textos acadêmicos, em que a democratização do acesso à informação e à tecnologia é um valor fundamental.

Portanto, o principal resultado deste trabalho não está apenas nas análises geradas, mas na demonstração prática de como a construção de um Data Warehouse estruturado transforma a forma como exploramos dados científicos. Antes, os dados eram brutos, inconsistentes e difíceis de analisar; após o processo de engenharia e modelagem, tornaram-se limpos, organizados e prontos para gerar conhecimento. Isso evidencia o papel da Engenharia de Sistemas como ferramenta integradora entre tecnologia, ciência e sociedade.

7. Conclusões e Trabalhos Futuros

7.1. Conclusões

O objetivo geral deste trabalho foi desenvolver e analisar um *Data Warehouse* (DW) voltado para a organização e exploração de dados de publicações científicas na área médica. Esse objetivo foi plenamente atingido, resultando em um sistema analítico funcional e estruturado, capaz de transformar dados brutos em informações úteis para pesquisa e gestão do conhecimento científico. Além disso, o projeto demonstrou um potencial ainda maior do que o inicialmente esperado, tanto em termos de aplicabilidade quanto de impacto acadêmico e social.

Ao longo do desenvolvimento, foi possível aplicar na prática os princípios da **Engenharia de Sistemas**, integrando diferentes ferramentas, tecnologias e etapas do ciclo de vida de um DW — desde a modelagem dimensional até a visualização analítica. O resultado é um modelo que organiza, trata e disponibiliza dados de forma estruturada e transparente, facilitando a análise de padrões de publicação, autores e locais de divulgação científica.

As contribuições deste trabalho podem ser analisadas sob três dimensões principais:

(a) Científica: ao estruturar dados provenientes do Scopus, o projeto oferece uma base consistente para análises bibliométricas e estudos sobre a dinâmica da produção científica em medicina. **(b) Tecnológica:** o uso de ferramentas open-source como DuckDB, PostgreSQL e Metabase demonstra que é possível construir soluções analíticas poderosas, reprodutíveis e de baixo custo, sem depender de infraestrutura complexa. **(c) Social:** o DW desenvolvido contribui para a democratização do acesso à informação científica, fortalecendo práticas de ciência aberta e colaborativa.

O projeto também reforça a importância da replicabilidade em contextos acadêmicos. Por utilizar tecnologias acessíveis e código aberto, o modelo proposto pode ser reproduzido e expandido facilmente por outros pesquisadores, tornando-se um ponto de partida para análises mais amplas e contínuas sobre o cenário da pesquisa médica.

7.2. Limitações e Trabalhos Futuros

Durante o desenvolvimento, algumas limitações foram identificadas, especialmente relacionadas ao desempenho das ferramentas e à abrangência das informações

disponíveis nas bases de dados. O carregamento e a visualização de grandes volumes de dados no Metabase apresentaram lentidão, e o PostgreSQL, embora estável, teve desempenho apenas razoável em consultas mais complexas. Assim, uma das melhorias futuras seria o uso de uma ferramenta de visualização mais robusta e otimizada para grandes volumes de dados, ou até mesmo a integração com soluções específicas de *Business Intelligence* em nuvem.

Outra limitação relevante foi o número reduzido de atributos disponíveis nas bases utilizadas, o que restringiu a profundidade das análises. Trabalhos futuros podem utilizar conjuntos de dados mais ricos, contendo informações como país de origem, instituição e laboratório, área de conhecimento e palavras-chave dos artigos, número de citações de cada artigo, fator de impacto das revistas, entre outros. Isso possibilitaria análises bibliométricas mais complexas e úteis para a comunidade científica e para a formulação de políticas de fomento à pesquisa.

Além disso, a automação do processo de ETL representa uma oportunidade importante de evolução. A integração com APIs de bases científicas, como Scopus ou PubMed, permitiria a atualização contínua dos dados, garantindo que o DW se mantenha sempre atualizado. Da mesma forma, o uso de técnicas de Inteligência Artificial, especialmente de **Processamento de Linguagem Natural (NLP)**, poderia ampliar o escopo das análises, possibilitando a identificação automática de temas, tendências e redes de colaboração entre autores.

Por fim, o aprimoramento do desempenho geral do sistema, aliado ao aumento da granularidade e diversidade dos dados, poderá elevar o modelo desenvolvido a um patamar mais completo e robusto, servindo não apenas como ferramenta de estudo, mas também como base de apoio real para a pesquisa científica. Dessa forma, o trabalho realizado consolida-se como um exemplo prático da aplicação da Engenharia de Sistemas no domínio da ciência e engenharia de dados, ao mesmo tempo em que abre caminhos para inovações futuras em análise científica e tecnológica.

Referências

[Chaudhuri and Dayal 1997] Chaudhuri, S. and Dayal, U. (1997). An overview of data warehousing and olap technology. *ACM SIGMOD Record*, 26(1):65–74.

[Golfarelli and Rizzi 2009] Golfarelli, M. and Rizzi, S. (2009). *Data Warehouse Design: Modern Principles and Methodologies*. McGraw-Hill.

[Inmon 2005] Inmon, W. H. (2005). *Building the Data Warehouse*. Wiley, 4 edition.

[Kanashiro 2007] Kanashiro, A. (2007). Um data warehouse de publicações científicas: Indexação automática da dimensão tópicos de pesquisa dos data marts. Dissertação de mestrado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo (ICMC-USP), São Carlos, SP. Versão revisada após a defesa. Orientador: Prof. Dr. Alneu de Andrade Lopes.

[Kimball et al. 1998] Kimball, R., Reeves, L., Ross, M., and Thornthwaite, W. (1998). *The Data Warehouse Lifecycle Toolkit*. Wiley Computer Publishing, New York.

[Kimball and Ross 2002] Kimball, R. and Ross, M. (2002). *The Data Warehouse Toolkit: The Complete Guide to Dimensional Modeling*. Wiley Computer Publishing, New York, 2 edition.

[Vassiliadis 2000] Vassiliadis, P. (2000). A survey of extract–transform–load technology. *International Journal of Data Warehousing and Mining*.

A. Apêndice – Consultas SQL dos Dashboards

Esta seção apresenta as consultas SQL utilizadas para geração das visualizações e métricas nos dashboards desenvolvidos no Metabase. As consultas foram executadas sobre o banco de dados *PostgreSQL* contendo as tabelas dimensionais (`dim_authors`, `dim_venues`, `dim_papers`) e a tabela fato (`fact_publications`), resultantes do processo de construção do Data Warehouse.

A.1. Contagem Geral de Entidades

As consultas a seguir retornam o número total de publicações, autores e locais de publicação (venues).

```
SELECT count(DISTINCT "public"."fact_publications"."paper_id")
AS "count"
FROM "public"."fact_publications"
WHERE "public"."fact_publications"."paper_id" IS NOT NULL;

SELECT count(DISTINCT "public"."fact_publications"."author_id")
AS "count"
FROM "public"."fact_publications"
WHERE "public"."fact_publications"."author_id" IS NOT NULL;

SELECT count(DISTINCT "public"."fact_publications"."venue_id")
AS "count"
FROM "public"."fact_publications"
WHERE "public"."fact_publications"."venue_id" IS NOT NULL;
```

A.2. Evolução do Número de Publicações por Ano

A consulta a seguir gera o gráfico *"Publications by Year"*, que mostra a evolução do número total de artigos publicados ao longo dos anos presentes na base de dados. A métrica é calculada pela contagem de identificadores únicos de artigos (`paper_id`) agrupados pelo campo de ano (`year`).

```
SELECT
    year AS "Year",
    COUNT(DISTINCT paper_id) AS "Total_Publications"
FROM public.fact_publications
WHERE year IS NOT NULL
GROUP BY year
ORDER BY year;
```

A.3. Criação de Visão Materializada de Periódicos Mais Produtivos

Para melhorar o desempenho e facilitar o uso no Metabase, foi criada uma visão materializada com os 10 locais de publicação mais relevantes.

```
CREATE MATERIALIZED VIEW top_venues AS
SELECT
  dv.venue AS nome_venue,
```

```
  COUNT(DISTINCT fp.paper_id) AS total_publicacoes
FROM fact_publications fp
JOIN dim_venues dv ON fp.venue_id = dv.venue_id
GROUP BY dv.venue;

-- Consulta no Metabase
SELECT * FROM top_venues ORDER BY total_publicacoes DESC LIMIT 10;
```

A.4. Médias de Publicações por Autor e por Local

As consultas abaixo retornam as médias de publicações por autor e por venue, permitindo análises comparativas.

```
SELECT
    AVG("papers_por_venue") AS "media_papers_por_venue"
FROM (
    SELECT
        "venue_id",
        COUNT(DISTINCT "paper_id") AS "papers_por_venue"
    FROM "fact_publications"
    WHERE "venue_id" IS NOT NULL
    GROUP BY "venue_id"
) AS "sub";

SELECT
    AVG(papers_por_autor) AS media_papers_por_autor
FROM (
    SELECT
        "author_id",
        COUNT(DISTINCT "paper_id") AS papers_por_autor
    FROM "fact_publications"
    WHERE "author_id" IS NOT NULL
    GROUP BY "author_id"
) sub;
```

A.5. Autores e Colaborações Científicas

O código a seguir identifica os autores com maior número de publicações.

```
SELECT
    da.author AS author,
    COUNT(fp.paper_id) AS total_papers
FROM public.fact_publications fp
JOIN public.dim_authors da
    ON fp.author_id = da.author_id
WHERE da.author IS NOT NULL
GROUP BY da.author, da.author_id
ORDER BY total_papers DESC
LIMIT 15;
```

A.6. Distribuição de Autores por Publicação

Essas consultas foram utilizadas para gerar os gráficos de distribuição e percentual de coautoria.

```
-- Distribuição do número de autores por publicação
SELECT
    num_authors,
    COUNT(*) AS num_papers
FROM (
    SELECT
        fp.paper_id,
        COUNT(DISTINCT fp.author_id) AS num_authors
    FROM public.fact_publications fp
    GROUP BY fp.paper_id
) AS sub
WHERE num_authors <= 20
GROUP BY num_authors
ORDER BY num_authors;

-- Percentual de papers com mais de um autor
SELECT
    SUM(CASE WHEN qtd_autores > 1 THEN 1 ELSE 0 END)::float
    / COUNT(*) * 100 AS perc_com_coautoria
FROM (
    SELECT
        paper_id,
        COUNT(DISTINCT author_id) AS qtd_autores
    FROM fact_publications
    GROUP BY paper_id
) sub;
```

A.7. Médias de Autores e Locais por Publicação

Por fim, as consultas a seguir foram usadas para calcular as médias de autores e locais por publicação.

```
SELECT
  AVG(autores_por_artigo) AS media_autores_por_artigo
FROM (
  SELECT
    fp.paper_id,
    COUNT(DISTINCT fp.author_id) AS autores_por_artigo
  FROM fact_publications fp
  WHERE fp.author_id IS NOT NULL
  GROUP BY fp.paper_id
) sub;

SELECT
```

```
    AVG("venues_por_paper") AS "media_venues_por_paper"
FROM (
    SELECT
        "paper_id",
        COUNT(DISTINCT "venue_id") AS "venues_por_paper"
    FROM "fact_publications"
    WHERE "venue_id" IS NOT NULL
    GROUP BY "paper_id"
) AS "sub";
```

Essas consultas serviram de base para as visualizações apresentadas nos dashboards do Metabase, permitindo analisar os principais indicadores bibliométricos da base de publicações médicas processada pelo Data Warehouse.